

주성분분석 및 트렌드 분류를 활용한 arXiv 논문 파급력 예측

팀명: Team 05

과목명: 비즈니스 애널리틱스를 위한 데이터 마이닝

1. 소개 (Introduction)

배경 및 문제제기

- 최근 AI 및 과학 기술의 급격한 발전으로 arXiv에 등록되는 논문의 수가 기하급수적으로 증가하고 있습니다 (특히 2026년 초 폭발적 증가).
- 수많은 논문 속에서 "어떤 논문이 향후 일주일간 트렌드(가장 많이 읽히고 공유될 논문)가 될 것인가?"를 사전에 예측하는 것은 연구자들에게 매우 중요한 가치를 지닙니다.

가설 및 목표

- 가설: 논문의 메타데이터(제목 길이, 특정 단어의 인기도, 출판 여부)와 속한 학문 분야의 특성을 결합하면, 해당 논문의 단기 트렌드 지수(Avg_MA_7D)를 예측할 수 있을 것이다.
- 목표: 데이터 마이닝의 분류(Classification) 기법을 활용하여, 논문을 3단계의 트렌드 수준(Low / Mid / High)으로 정확히 분류하는 예측 모델을 개발한다.

2. 방법 (Methods) - 데이터 및 전처리

데이터 설명

- 수집 데이터: arXiv 논문 메타데이터 약 82,688건 (2025년 ~ 2026년 4월 중심)
- 주요 특징(Features): 8개 (제목 길이, 단어 수, 제목 인기도 점수, DOI 인용률, 출판 여부 등)

핵심 전처리 로직

- 분야 지배효과 보정 (`Category_Covariance_norm`): 특정 학문 분야(예: cs.CL) 자체가 가지는 인기도가 논문의 개별 인기도를 묻히게 하는 현상을 발견했습니다. 이를 해결하기 위해 분야별 평균 Covariance로 데이터를 정규화하여, 논문 ****고유의 특징(Intrinsic)****이 잘 드러나도록 설계했습니다.
- 타겟 변수 구간화: 연속형 변수인 7일 이동평균(`Avg_MA_7D`)을 3분위수 기준으로 정확히 3등분하여 클래스 불균형을 방지했습니다. (Low: 27,591건, Mid: 27,542건, High: 27,555건)

3. 방법 (Methods) - 모델 설계

모델 선정 이유 및 수업 내용 적용

1. **Decision Tree (메인 모델)**: 결과에 대한 직관적인 해석(규칙 도출)이 가능하여 학술 데이터 분석에 적합합니다.
2. **K-Nearest Neighbors (KNN)**: 거리를 기반으로 유사한 스펙의 논문들이 비슷한 트렌드를 가지는지 확인하기 위한 베이스라인으로 선정했습니다.
3. **Bagging & AdaBoost (앙상블)**: 단일 의사결정나무의 과적합(Overfitting)을 방지하고 일반화 성능을 끌어올리기 위해 배운 기법들을 적용했습니다.

파라미터 튜닝

- **Decision Tree**: 과적합을 막기 위해 `max_depth=8`, `min_samples_leaf=50` 으로 제한하여 가지치기(Pruning)를 수행했습니다.
- **KNN**: 군집의 안정성을 위해 `k=11` 을 설정하고 `StandardScaler` 로 스케일링을 적용했습니다.

4. 결과 (Results) - 성능 평가 지표

평가지표 선정 이유

- 3개의 클래스(Low/Mid/High) 비율이 완벽하게 균형을 이루고 있으므로 ****정확도 (Accuracy)****가 직관적입니다.
- 다중 클래스 분류에서의 전반적인 예측 밸런스를 확인하기 위해 ****F1-Score (Macro)****를 메인 지표로 함께 사용했습니다.

검증 결과 (Random Split: 80/20)

모델	Accuracy	F1 (Macro)
DecisionTree	0.815	0.816
KNN (k=11)	0.677	0.668
AdaBoost	0.798	0.798

5. 결과 (Results) - 현실 적용성 검증 (Time Split)

랜덤 분할은 미래의 데이터가 과거를 예측하는 데 쓰이는 미래 참조(Data Leakage) 문제가 발생할 수 있습니다. 이를 검증하기 위해 ****시간 기반 분할(과거 데이터로 미래 예측)****을 수행했습니다.

검증 방식

- 학습(Train): 2026년 3월 이전 데이터 (61,842건)
- 테스트(Test): 2026년 4월 최신 데이터 (20,846건)

Time Split 평가 결과

- DecisionTree F1: 0.816 → **0.772** (현실 성능 방어 성공)
- Bagging F1: 0.829 → **0.780**

새로운 미래의 달(4월) 데이터에 대해서도 78%의 F1 점수를 기록하며, 본 모델이 실제 프로덕션 환경에서도 안정적으로 트렌드를 예측할 수 있음을 입증했습니다.

6. 결론 (Conclusion)

프로젝트 요약 및 인사이트

1. 분야의 힘: 논문 트렌드에 가장 큰 영향을 미치는 것은 "해당 논문이 어떤 분야에 속해 있는가"였습니다. (`Category_Covariance_norm` 의 중요도 0.710)
2. 앙상블의 위력: 수업에서 다룬 Bagging 기법이 단일 트리의 한계를 극복하고 예측률을 가장 높였습니다.
3. 시계열 검증의 중요성: Time Split 검증을 통해, 무작위 교차검증의 함정을 피하고 현실적인 성능 지표를 확보했습니다.

한계점 및 향후 개선점 (외삽 문제)

- 한계점 (Extrapolation Limit): 이번 프로젝트에서 배운 모델들(Tree, KNN)은 훌륭한 분류기이지만, 미래의 상승 추세(예: 5월 논문 발생량)를 그려내는 시계열 회귀 예측(Forecasting)에는 적합하지 않았습니다. 미래를 경험해 본 적이 없기 때문에 값이 수평으로 뻗어버리는 문제가 확인되었습니다.

감사합니다. Q&A