

주성분분석 및 트렌드 분류를 활용한 arXiv 논문 파급력 예측

팀명: Team 05

과목명: 비즈니스 애널리틱스를 위한 데이터 마이닝

1. 소개 (Introduction)

배경 및 문제제기

- 최근 AI 및 과학 기술의 급격한 발전으로 arXiv에 등록되는 논문의 수가 기하급수적으로 증가하고 있습니다 (특히 2026년 초 폭발적 증가).
- 수많은 논문 속에서 "어떤 논문이 향후 일주일간 트렌드(가장 많이 읽히고 공유될 논문)가 될 것인가?"를 사전에 예측하는 것은 연구자들에게 매우 중요한 가치를 지닙니다.

가설 및 목표

- **가설:** 논문의 메타데이터(제목 길이, 특정 단어의 인기도, 출판 여부)와 속한 학문 분야의 특성을 결합하면, 해당 논문의 단기 트렌드 지수(Avg_MA_7D)를 예측할 수 있을 것이다.
- **목표:** 데이터 마이닝의 분류(Classification) 기법을 활용하여, 논문을 3단계의 트렌드 수준(Low / Mid / High)으로 정확히 분류하는 예측 모델을 개발한다.


2. 방법 (Methods) - 데이터 및 전처리

데이터 설명

- 수집 데이터: arXiv 논문 메타데이터 약 82,688건 (2025년 ~ 2026년 4월 중심)
- 주요 특징(Features): 8개 (제목 길이, 단어 수, 제목 인기도 점수, DOI 인용률, 출판 여부 등)

핵심 전처리 로직



- 분야 지배효과 보정 (`Category_Covariance_norm`): 특정 학문 분야(예: cs.CL) 자체가 가지는 인기도가 논문의 개별 인기도를 묻히게 하는 현상을 발견했습니다. 이를 해결하기 위해 분야별 평균 Covariance로 데이터를 정규화하여, 논문 **고유의 특징(Intrinsic)**이 잘 드러나도록 설계했습니다.
- 타겟 변수 구간화: 연속형 변수인 7일 이동평균(`Avg_MA_7D`)을 3분위수 기준으로 정확히 3등분하여 클래스 불균형을 방지했습니다. (Low: 27,591건, Mid: 27,542건, High: 27,555건)



제목에 사용된 단어 빈도 분석 → Title Popularity Score 산출 기반



2-1. 방법 (Methods) - PCA: 왜 표준화가 필요한가

- 표준화 전: `Category_Covariance` 변수의 분산($\approx 63,634$)이 다른 변수에 비해 압도적으로 커서, 첫 번째 주성분(PC1)이 전체 분산의 80.2%를 독점했습니다. 이는 사실상 변수 1개만 보는 것과 같은 효과입니다.
- 표준화 후: 모든 변수를 동일한 척도로 맞추자 PC1의 비중이 17.6%로 낮아지고, 여러 변수의 정보가 균형 있게 반영되었습니다.
- Scree Plot: 누적 설명 분산 80%를 달성하려면 주성분 7개가 필요함을 확인했습니다. → 단순 차원축소보다, 원본 특징을 직접 활용하는 분류 모델이 해석에 더 효율적이라는 판단의 근거가 되었습니다.



2-2. 방법 (Methods) - PCA: 논문 분포와 특징 구조


- 좌측 (산점도): PC1-PC2 평면에 논문들을 투영하여, 트렌드 수준에 따른 분포 경향성을 시각적으로 확인했습니다.
- 우측 (Loadings): 각 변수가 주성분 축을 구성하는 데 얼마나 기여하는지를 보여줍니다. 이를 통해 어떤 변수들이 서로 묶여 같은 의미축을 형성하는지 파악할 수 있었습니다.



2-3. 방법 (Methods) - 제목 인기 점수(Title Popularity Score)

- 제목에 사용된 단어들의 빈도표를 기반으로, 각 논문 제목의 "인기 단어 사용도"를 점수화한 `Title_Popularity_Score` 를 새로 만들었습니다.
- 이 점수를 포함해 16개 변수로 PCA를 재실행한 결과, **PC3 "제목 길이·스타일 축"**에 가장 강하게 연관됨을 확인했습니다 (그래프의 빨간 테두리 표시).
- 기존의 제목 길이/단어 수 변수와는 다른 정보를 담고 있었으나, 최종 모델에서는 핵심 7개 특징에 집중하기 위해 보류했습니다.

제목 인기점수(Title_Popularity_Score) 포함 — 주성분 4개 (빨간 테두리=새 점수)



3. 방법 (Methods) - 모델 설계

모델 선정 이유 및 수업 내용 적용



- **Decision Tree (메인 모델):** 결과에 대한 직관적인 해석(규칙 도출)이 가능하여 학술 데이터 분석에 적합합니다.
- **K-Nearest Neighbors (KNN):** 거리를 기반으로 유사한 스펙의 논문들이 비슷한 트렌드를 가지는지 확인하기 위한 베이스라인으로 선정했습니다.
- **Bagging & AdaBoost (앙상블):** 단일 의사결정나무의 과적합(Overfitting)을 방지하고 일반화 성능을 끌어올리기 위해 배운 기법들을 적용했습니다.

파라미터 튜닝

- **Decision Tree:** 과적합을 막기 위해 `max_depth=8`, `min_samples_leaf=50` 으로 제한하여 가지치기(Pruning)를 수행했습니다.
- **KNN:** 군집의 안정성을 위해 `k=11` 을 설정하고 `StandardScaler` 로 스케일링을 적용했습니다.



4-1. 결과 (Results) - 클래스 분포 및 모델 성능

- 타겟 변수 Avg_MA_7D 를 3분위수로 나눠 Low / Mid / High 클래스 균형을 확보했습니다 (각 ~27,5xx건).
- 핵심 7개 특징(분야 특징 포함) 사용 시 DecisionTree / RandomForest가 F1(Macro) **0.81** 수준으로 가장 우수했습니다.
- 분야 특징(Category_Covariance_norm)을 제외하면 F1이 0.48로 급락 → "분야 정체성"이 트렌드를 결정하는 핵심 신호임을 정량적으로 확인했습니다.



4-2. 결과 (Results) - 혼동행렬 및 특징 중요도


- 혼동행렬 (좌): Low와 High 양극단은 비교적 잘 구분하지만, 중간(Mid) 클래스에서 일부 혼동이 발생합니다. 트렌드가 점진적으로 변화하는 특성이 반영된 결과입니다.
- 특징 중요도 (우): `Category_Covariance_norm` (약 0.68)이 가장 크고, `Days_Since_Update` (약 0.15), `Paper_Age_Years` (약 0.09) 순으로 나타났습니다.



4-3. 결과 (Results) - Decision Tree 구조 시각화

- 최상위 분기 기준이 `Category_Covariance_norm` 으로 나타나, 분야 동조성이 트렌드 수준을 가르는 첫 번째 기준임을 시각적으로 확인할 수 있습니다.
- `max_depth=8` , `min_samples_leaf=50` 으로 가지치기하여 과적합을 방지하면서도 해석 가능성을 확보했습니다.

Decision Tree Structure (top 3 levels, pruned)



4-4. 결과 (Results) - 현실 적용성 검증 (Time Split)

랜덤 분할은 미래의 데이터가 과거를 예측하는 데 쓰이는 미래 참조(Data Leakage) 문제가 발생할 수 있습니다. 이를 검증하기 위해 시간 기반 분할(과거 데이터로 미래 예측)을 수행했습니다.


검증 방식

- 학습(Train): 2026년 3월 이전 데이터 (61,842건)
- 테스트(Test): 2026년 4월 최신 데이터 (20,846건)

Time Split 평가 결과



- DecisionTree F1: 0.816 → **0.772** (현실 성능 방어 성공)
- Bagging F1: 0.829 → **0.780**

새로운 미래의 달(4월) 데이터에 대해서도 78%의 F1 점수를 기록하며, 본 모델이 실제 프로덕션 환경에서도 안정적으로 트렌드를 예측할 수 있음을 입증했습니다.



5. 한계점 및 향후 개선점 - 외삽(Extrapolation) 문제

- Decision Tree, KNN, AdaBoost의 회귀(Regressor) 버전으로 2026년 5월 논문 발생량 추세를 예측해 보았습니다.
- 실제 추세선은 계속 상승하지만, 트리/거리 기반 모델은 학습 데이터에서 본 값의 범위를 벗어나지 못해 5월 구간에서 값이 **평평하게(flatline)** 예측되었습니다.
- 이는 수업에서 배운 모델들이 훌륭한 분류기이지만, 미래의 새로운 추세를 "그려내는" 시계열 회귀 예측(Forecasting)에는 한계가 있음을 보여주는 사례입니다.
- 향후 개선:** 차분, 추세 성분 분리 등 시계열 특화 기법과의 결합이 필요합니다.



6. 결론 (Conclusion)

프로젝트 요약 및 인사이트

- 분야의 힘: 논문 트렌드에 가장 큰 영향을 미치는 것은 "해당 논문이 어떤 분야에 속해 있는가"였습니다. (`Category_Covariance_norm` 의 중요도 0.710)
- 앙상블의 위력: 수업에서 다룬 Bagging 기법이 단일 트리의 한계를 극복하고 예측률을 가장 높였습니다.
- 시계열 검증의 중요성: Time Split 검증을 통해, 무작위 교차검증의 함정을 피하고 현실적인 성능 지표를 확보했습니다.

한계점 및 향후 개선점 (외삽 문제)

- 한계점 (Extrapolation Limit): 이번 프로젝트에서 배운 모델들(Tree, KNN)은 훌륭한 분류기이지만, 미래의 상승 추세(예: 5월 논문 발생량)를 그려내는 시계열 회귀 예측(Forecasting)에는 적합하지 않았습니다. 미래를 경험해 본 적이 없기 때문에 값이 수평으로 뻗어버리는 문제가 확인되었습니다.

감사합니다. Q&A